Sistema di Previsione Cancellazioni Prenotazioni Hotel (ML)

Previsione della probabilità che una prenotazione sia **confermata** (non cancellata)

Il Problema

Molte prenotazioni vengono cancellate, causando perdita di ricavi e camere vuote nei periodi di alta domanda.

L'Obiettivo

Stimare la **probabilità di conferma** per ogni prenotazione, identificando quelle a rischio prima che si cancellino.

L'Output

Supporto a **pricing dinamico** e **gestione della disponibilità** camere in tempo reale.

Target e Valore per il Business

Definizione del Target

La variabile originale del dataset è **is_canceled** (1 = cancellata, 0 = non cancellata).

Nel progetto è stata trasformata in: **booking_confirmed = 1 − is_canceled**, dove 1 = confermata e 0 = cancellata. Questo rende l'output più intuitivo e orientato al business.

Valore Business Generato

- **Pricing dinamico:** alta probabilità di conferma → prezzo leggermente più alto; bassa probabilità → piccolo sconto per incentivare la conferma.
- **Yield management:** migliore allocazione delle camere nei periodi di alta domanda, riducendo il rischio di overbooking o camere vuote.
- **Riduzione cancellazioni:** applicare deposito o regole di cancellazione diverse per le prenotazioni classificate ad alto rischio.

Workflow — Parte 1: Training sul Dataset Storico (2015–2017)

Il modello viene addestrato su dati storici seguendo una pipeline strutturata in 6 fasi.

Dataset Storico

Hotel Booking Demand (Kaggle) —

~120.000 prenotazioni, 30+ variabili.

Target: booking_confirmed.

Data Cleaning

Gestione null (company, agent, country), riduzione categorie rare, controllo outlier, creazione variabile target.

Feature Engineering

Nuove variabili: season, weekend_flag, lead_time_group, stay_type, trip_type, country_group.

EDA

Analisi esplorativa: lead_time alto → più cancellazioni; Direct/Corporate → più affidabili; special requests → segnale di conferma.

Preprocessing & Modeling

Due approcci di preprocessing (manuale + Dataiku automatico). Testati: Logistic Regression (AUC 0.91) e LightGBM (AUC 0.942).

Evaluation & Feature Importance

LightGBM scelto come modello finale. Top feature: deposit_type (20%), country_group (19%), market_segment (11%).

Il modello LightGBM addestrato su questo dataset viene salvato e applicato al dataset 2024 per la validazione.

Workflow — Parte 2: Validazione sul Dataset 2024

Il modello salvato viene applicato su dati completamente nuovi per testarne la capacità di generalizzazione.

Dataset 2024

Nuovo dataset hotel_bookings_updated_2024 — stesso schema del dataset storico, dati completamente nuovi (~120000 prenotazioni).

Preprocessing Identico + row_id

Stesso preprocessing del Ramo 1. Aggiunta chiave univoca row_id per join stabile tra predizioni e target reale.

Scoring con Modello Salvato

Rimozione target → scoring con LightGBM salvato → output: proba_0, proba_1, prediction per ogni prenotazione.

Valutazione Finale

Join predizioni + target reale. Risultati: Accuracy 86.63%, Precision 87.66%, Recall 91.46%, F1 89.52%.

Output Finale

Le previsioni del modello alimentano 8 strategie operative concrete: depositi intelligenti, pricing dinamico, gestione canali, ottimizzazione agenti, valorizzazione clienti con richieste speciali e altro.

86.63%	87.66%	91.46%	89.52%
Accuracy	Precision	Recall	F1-Score

Dataset e Variabili

Fonte e Dimensione

Dataset storico: Hotel Booking Demand (Kaggle)

Righe: ~120.000

Variabili: 30+ di tipo diverso: numeriche, categoriche, temporali

Unità di analisi: 1 riga = 1 prenotazione

Variabili Principali

- ### Tempo

  lead_time, arrival_date_year/month/day, stays_in_week_nights, stays_in_weekend_nights, total_nights

- ### Prezzo e Condizioni

  adr, deposit_type

- ### Cliente e Canale

  market_segment, distribution_channel, customer_type, country

- ### Segnali di Intenzione

  total_of_special_requests, booking_changes, required_car_parking_spaces, days_in_waiting_list

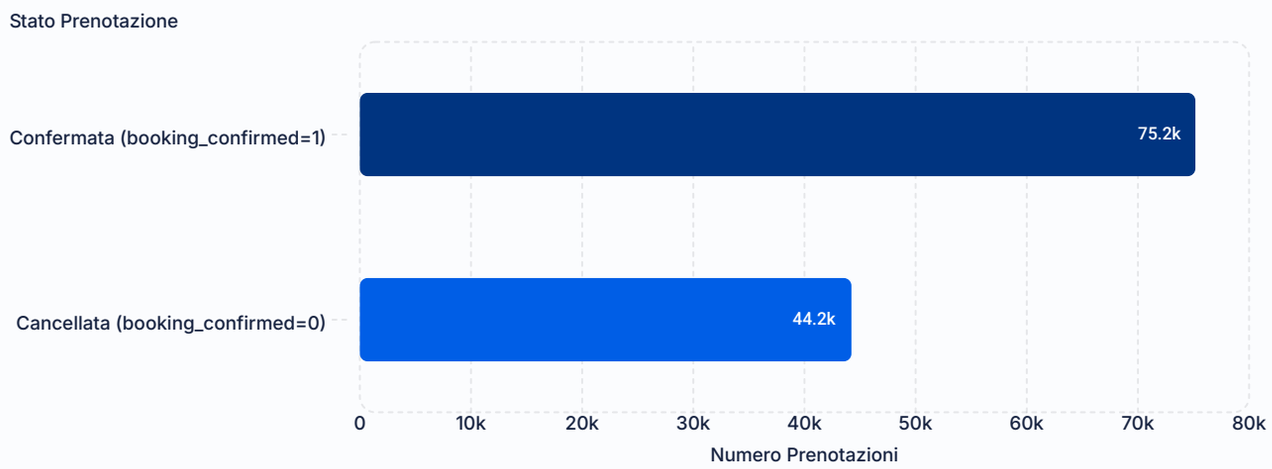

La distribuzione del target mostra che circa il **63%** delle prenotazioni risulta **confermata**,

mentre il **37%** viene **cancellata** — una proporzione significativa che giustifica l'adozione di un modello predittivo.

Preparazione Dati e Nuove Feature

Il dataset grezzo è stato trasformato in due fasi successive: prima la pulizia, poi l'arricchimento con nuove feature ingegnerizzate.

Pulizia dei Dati

- Controllo valori mancanti e tipi di dato (es. **company**, **agent**, **country**)
- Gestione dei null: sostituzione dove ha senso (es. company/agent → 0) e rimozione righe quando necessario
- Controllo e riduzione delle categorie rare per diminuire la complessità del modello

Feature Engineering — Nuove Colonne

- **arrival_date:** unione di anno, mese e giorno di arrivo
- **season:** stagione di arrivo (winter / spring / summer / autumn)
- **weekend_flag:** flag per soggiorni che includono il weekend
- **lead_time_group:** fasce temporali di anticipo prenotazione
- **stay_type:** classificazione della durata del soggiorno
- **trip_type:** tipo di viaggio (business / weekend / mixed)
- **country_group:** top paesi + raggruppamento "Other"

Il Tempo Influenza il Rischio di Cancellazione

Insight chiave: lead_time è una delle variabili più importanti dell'intero modello. Le prenotazioni last minute sono molto più stabili di quelle fatte con largo anticipo.

Tasso di Conferma per Lead Time Group

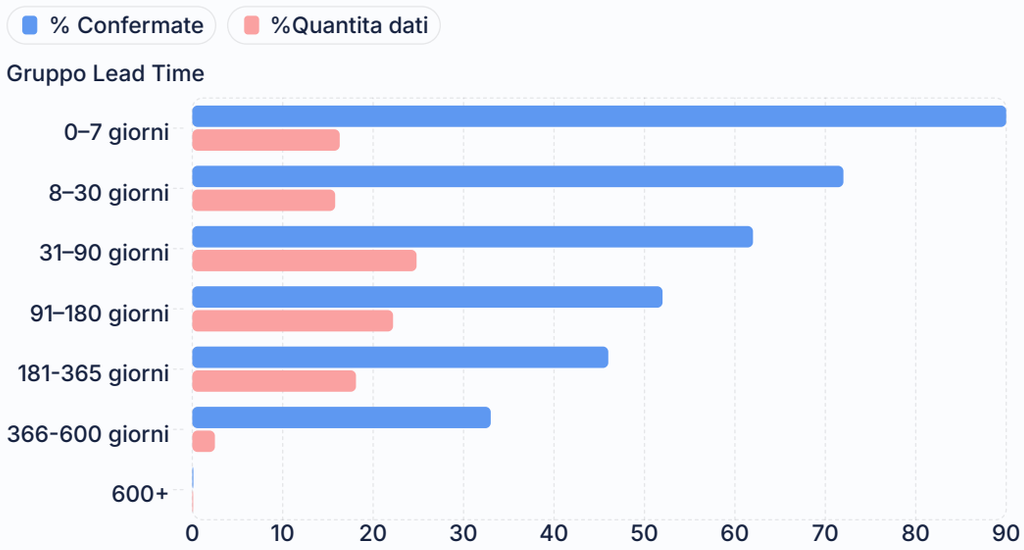

Tasso di Conferma per Stagione

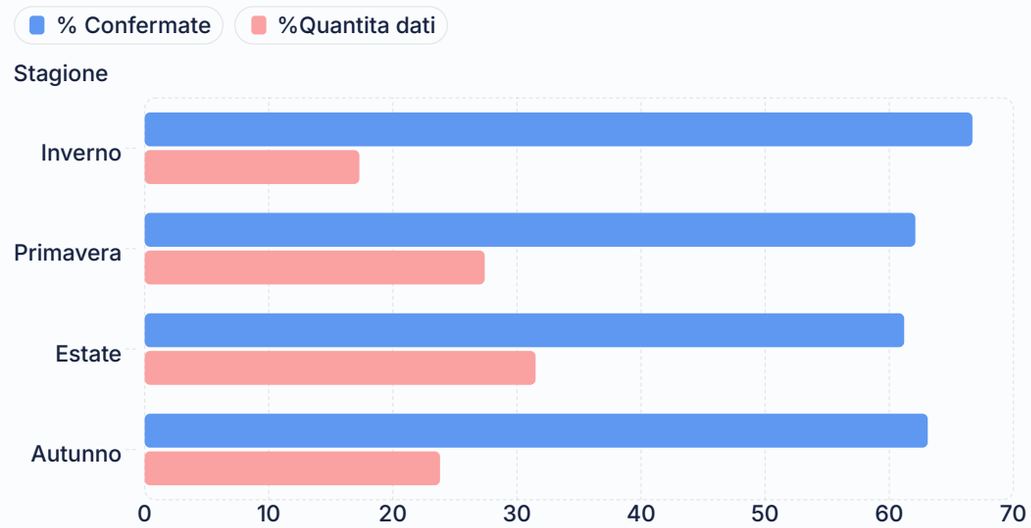

Source:

Last Minute (0–7 giorni)

Circa il **90% delle prenotazioni** viene confermata. Chi prenota all'ultimo momento ha quasi certamente intenzione di soggiornare.

Anticipo Elevato (180+ giorni)

Il rischio di cancellazione aumenta drasticamente. Oltre i 600 giorni di anticipo, **quasi tutte le prenotazioni vengono cancellate**.

Effetto Stagionale

In **estate** la probabilità di cancellazione è leggermente più alta rispetto alle altre stagioni, probabilmente per la maggiore offerta alternativa.

Il Tipo di Cliente e il Canale Influenzano la Stabilità

Conferma per Market Segment e Customer Type

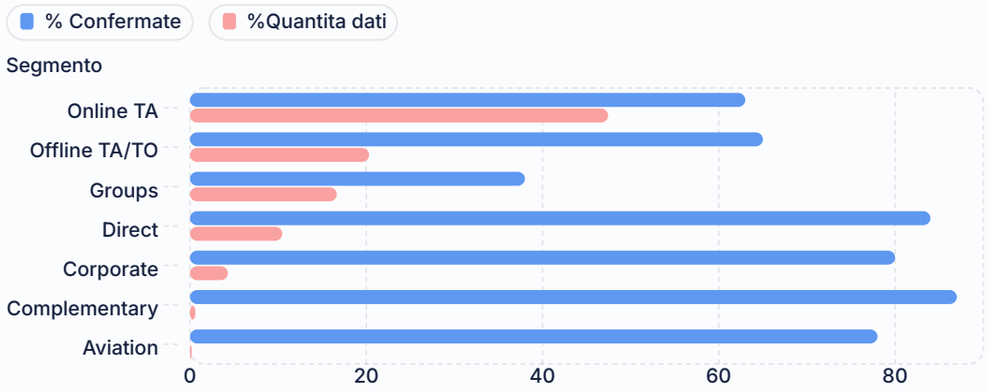

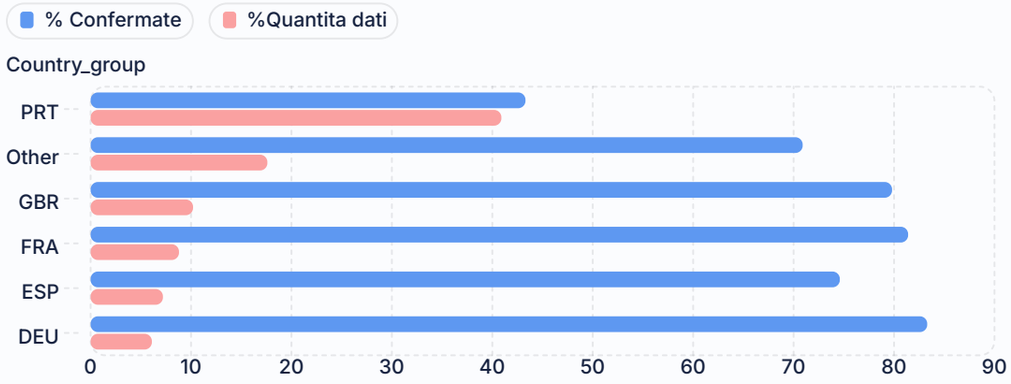

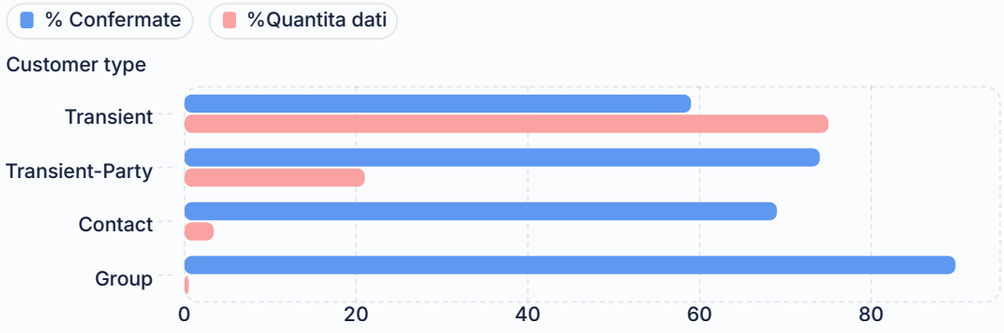

Messaggi Principali

Market Segment: canali diretti più affidabili

Complementary (87%) e Direct (84%) hanno i tassi di conferma più alti. Online TA, pur dominando con il 47.4% del volume, conferma solo il 63% delle prenotazioni. Groups è il canale più a rischio: solo 38% di conferme.

Country Group: il Portogallo è un'anomalia

Il Portogallo rappresenta il 40.9% del volume ma conferma solo il 43.3% delle prenotazioni — il tasso più basso. Germania (83.3%) e Francia (81.4%) sono i paesi più affidabili.

Customer Type: Transient domina ma è volatile

Il 75% delle prenotazioni è Transient, con solo il 59% di conferme. I clienti Group sono i più affidabili (89.8%) ma rappresentano appena lo 0.5% del totale.

Segnali che Indicano Alta Probabilità di Conferma

Le richieste speciali, le modifiche alla prenotazione e la richiesta di parcheggio sono i segnali più forti di reale intenzione di soggiorno. Chi si impegna attivamente nella prenotazione raramente la cancella.

Conferma per Numero di Richieste Speciali

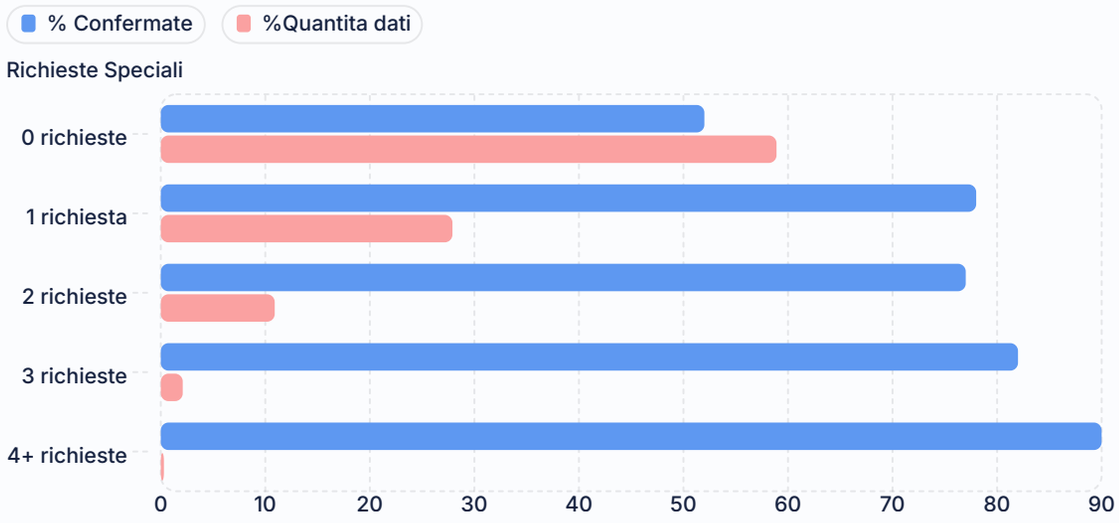

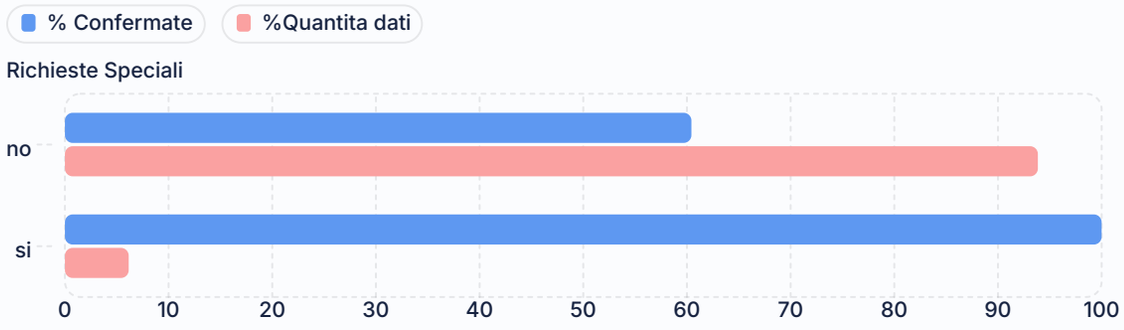

Messaggi Chiave

Più richieste speciali = più conferme

Il salto è netto: da 0 richieste (52% di conferme, 58.9% del volume) a 1 sola richiesta (78%). Con 4+ richieste si arriva al 90%. Ogni richiesta aggiuntiva è un segnale concreto di intenzione reale di soggiorno.

Richiesta parcheggio: segnale quasi infallibile

Solo il 6.15% dei clienti richiede parcheggio, ma il 100% di questi conferma la prenotazione. Chi pianifica la logistica del viaggio non cancella mai.

"L'analisi esplorativa mostra che la probabilità di conferma dipende principalmente da: anticipo della prenotazione, canale di prenotazione e segnali di coinvolgimento del cliente."

Preparazione dei Dataset per il Machine Learning

Primo Approccio: Preprocessing **Manuale**

Descrizione: Trasformazioni applicate manualmente

Operazioni:

- Encoding delle variabili categoriche
- Normalizzazione delle variabili numeriche

Vantaggio: Controllo diretto delle trasformazioni applicate ai dati

Secondo Approccio: Preprocessing **Automatico** (Dataiku)

Descrizione: Preprocessing gestito direttamente da Dataiku durante l'addestramento

Operazioni automatiche:

- Encoding delle variabili categoriche
- Scaling delle variabili numeriche
- Gestione dei valori mancanti

Vantaggio: Semplifica il processo di modellazione

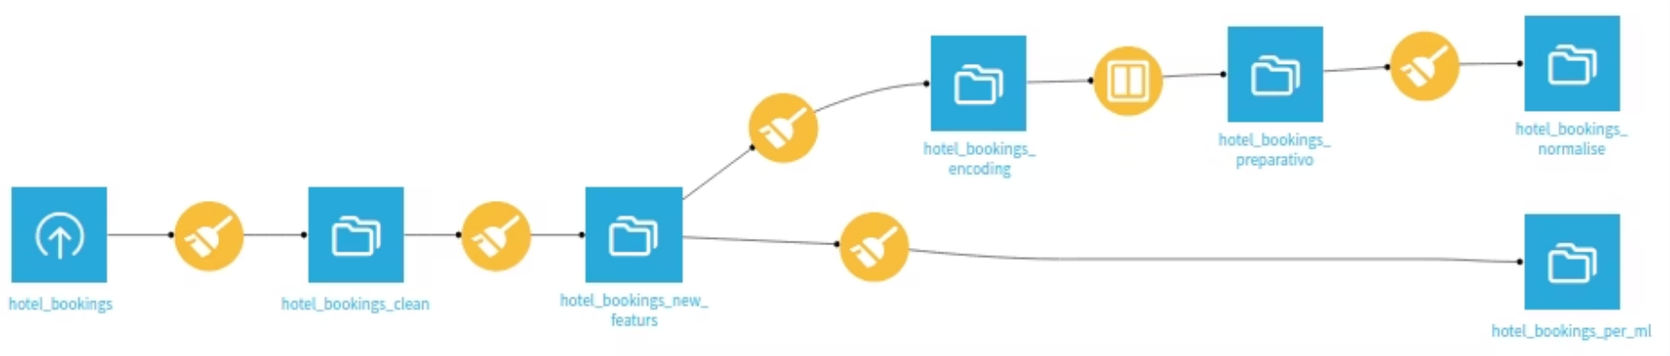

Confronto dei Risultati

Modello	Manuale	Automatico (Dataiku)
LightGBM	0.942	0.942
Logistic Regression	0.911	0.910

Modelli di Machine Learning Utilizzati

Il problema è una **classificazione binaria**: il modello deve prevedere se una prenotazione sarà confermata (1) o cancellata (0). Sono stati testati due approcci complementari.

Modello 1 — Logistic Regression (Baseline)

- Modello lineare, semplice e interpretabile
- Utilizzato come punto di riferimento (baseline) per valutare il miglioramento dei modelli più complessi
- Parametro principale: **C = 1** (Dataiku ha utilizzato una procedura di **hyperparameter search** per trovare il valore migliore)
- Vantaggi: veloce da addestrare, facile da spiegare al business

Modello 2 — LightGBM (Modello Finale)

- Il modello utilizza il metodo: **Gradient Boosting Decision Tree**
- Adatto a dataset di grandi dimensioni (~120.000 righe)
- Cattura relazioni non lineari tra le variabili
- Gestisce bene **variabili numeriche e categoriali**
- **Parametri principali:**
  - ~102 alberi (n_estimators)
  - 31 foglie per albero (num_leaves)
  - Learning rate = 0.05

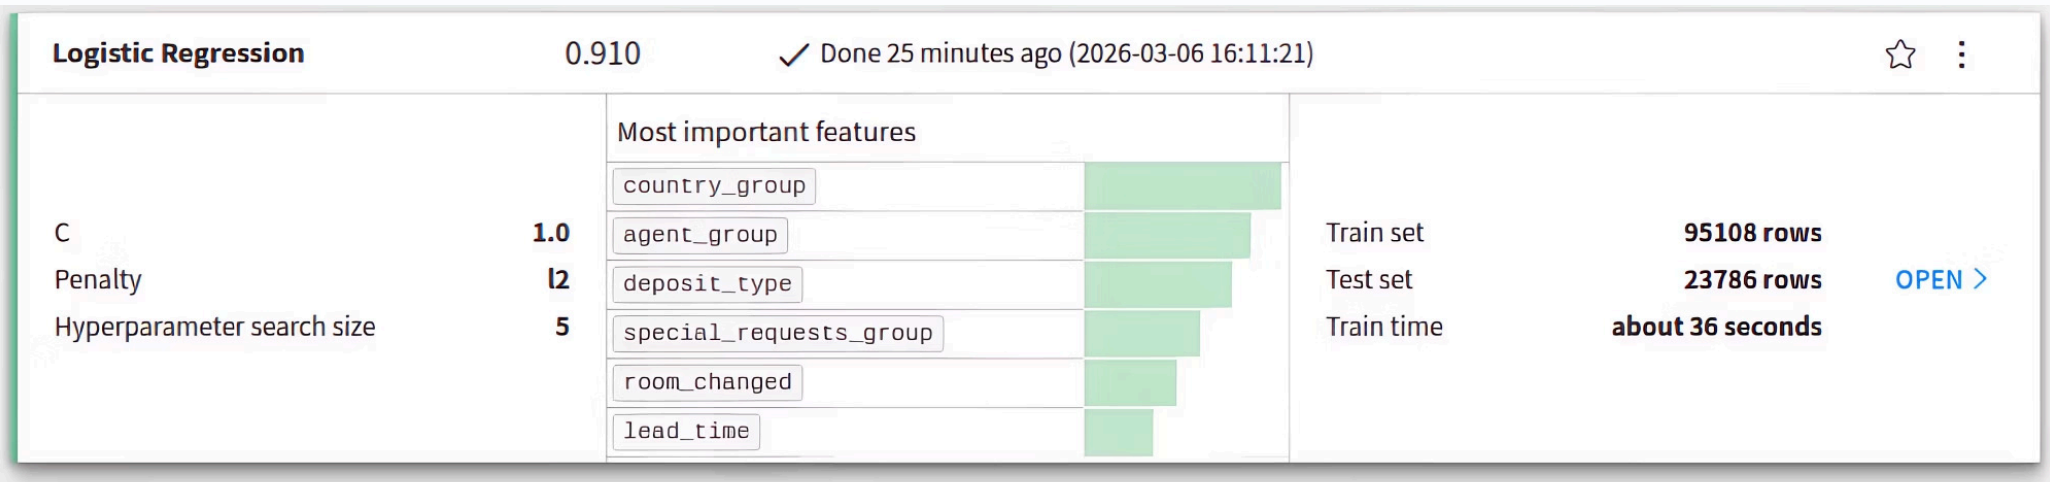

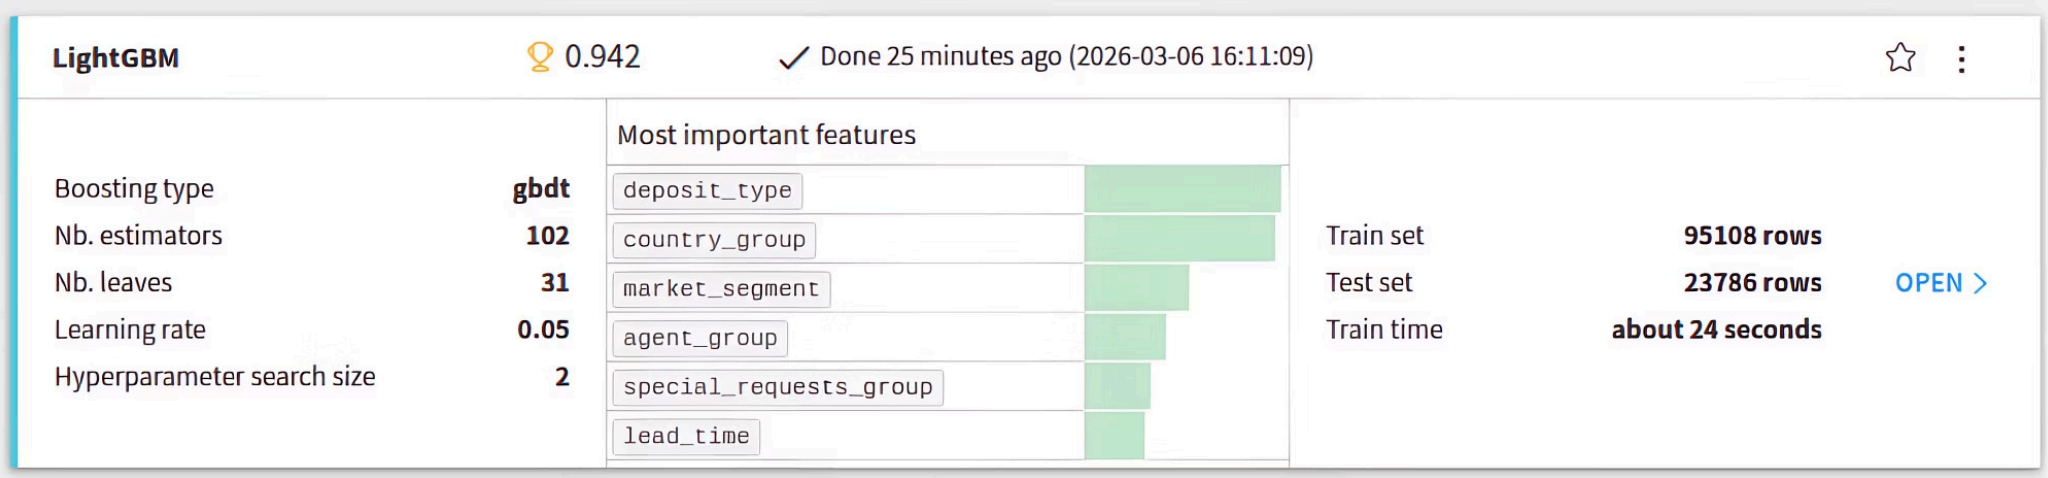

Confronto delle Performance

Metrica Utilizzata: ROC AUC

Il ROC AUC misura la capacità del modello di distinguere correttamente tra prenotazioni confermate e cancellate, indipendentemente dalla soglia di classificazione scelta.

0.5

Modello Casuale

Nessuna capacità discriminante — equivale a lanciare una moneta.

0.91

Logistic Regression

Ottimo risultato per un modello baseline lineare.

0.942

LightGBM

Modello scelto per l'analisi finale.
Risultato eccellente.

Interpretazione dei Risultati

- Entrambi i modelli performano **molto bene**, superando ampiamente la soglia di 0.8 considerata un buon modello
- **LightGBM ottiene risultati migliori** (+0.03 rispetto alla Logistic Regression)
- Il modello scelto per l'analisi finale è **LightGBM**

Le ragioni principali sono:

- LightGBM riesce a catturare **relazioni più complesse tra le variabili**
- gestisce meglio dataset **di grandi dimensioni**
- è particolarmente efficace con **molte variabili categoriali**

Il modello riesce a distinguere in modo molto accurato tra prenotazioni confermate e cancellate.

Quali Variabili Influenzano di Più la Conferma?

Feature Importance — LightGBM (Top 7)

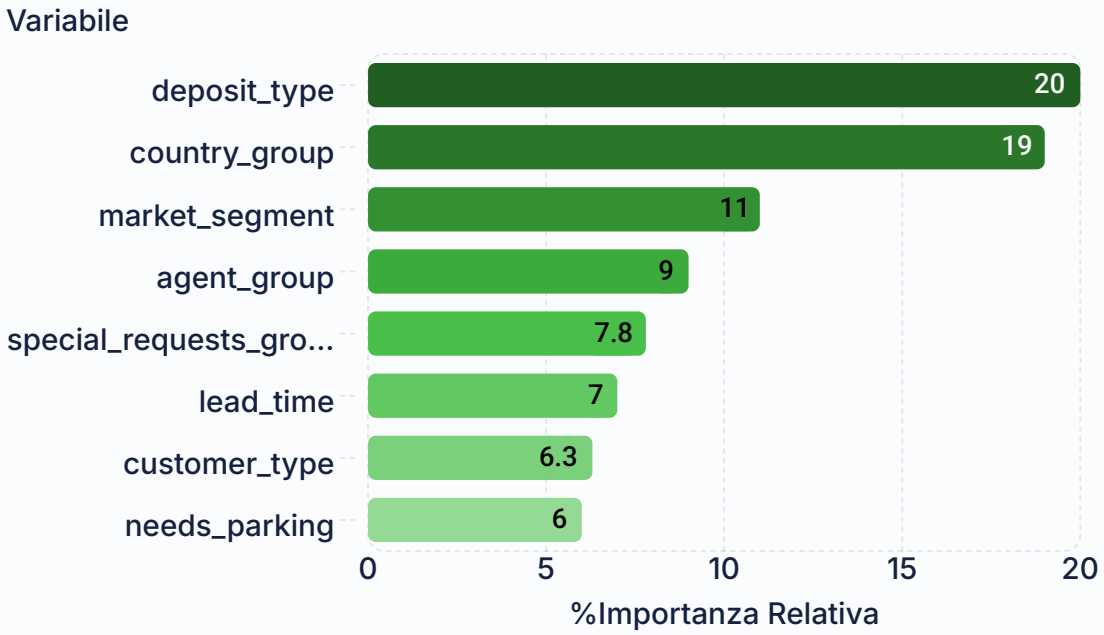

Conclusione: Il modello non decide in modo casuale — usa variabili coerenti con il comportamento reale dei clienti, confermando la solidità dell'approccio.

Interpretazione delle Variabili Chiave

→ Deposit Non Rimborsabile

Chi paga un deposito non rimborsabile ha meno incentivo a cancellare → **meno cancellazioni**.

→ Country Group

Alcuni paesi mostrano comportamenti sistematicamente diversi nella propensione alla cancellazione.

→ Lead Time Alto

Più è lontana la data di arrivo al momento della prenotazione, **più alto è il rischio** di cancellazione.

→ Richieste Speciali e Parcheggio

Molte richieste speciali e la richiesta di parcheggio sono **segnali forti di reale intenzione** di soggiorno.

Strategie di Business (1/2) — Gestione del Rischio

Depositi Intelligenti

Insight: deposit_type è la variabile più importante del modello

Azione: Deposito parziale/non rimborsabile per prenotazioni ad alto rischio; deposito flessibile per clienti affidabili

Obiettivo: Ridurre le cancellazioni mantenendo competitività

Gestione Canali di Vendita

Insight: market_segment influisce molto sul comportamento dei clienti

Azione: Incentivare Direct e Corporate; politiche più restrittive per OTA

Obiettivo: Migliorare la qualità delle prenotazioni

Strategie per Paese di Origine

Insight: country_group è tra le feature più importanti del modello

Azione: Offerte dedicate per paesi affidabili; conferma anticipata o depositi per paesi ad alto rischio

Obiettivo: Migliorare il tasso di conferma internazionale

Ottimizzazione tramite Agenti

Insight: agent_group è una variabile molto importante nel modello

Azione: Rafforzare collaborazione con agenti virtuosi; monitorare agenti con alta cancellazione

Obiettivo: Migliorare la qualità delle prenotazioni da agenzie

Strategie di Business (2/2) — Valorizzazione e Revenue

Gestione Prenotazioni Anticipate

Insight: lead_time alto indica maggiore rischio di cancellazione

Azione: Promozioni per chi conferma vicino alla data di arrivo; deposito per prenotazioni molto anticipate

Obiettivo: Ridurre l'incertezza delle prenotazioni future

Offerte per Clienti con Parcheggio

Insight: needs_parking indica clienti con soggiorni più strutturati (famiglie, viaggi lunghi)

Azione: Pacchetti con parcheggio incluso; offerte per soggiorni più lunghi

Obiettivo: Aumentare la durata media del soggiorno

Valorizzare Clienti con Richieste Speciali

Insight: special_requests_group è correlata con prenotazioni più affidabili

Azione: Offrire upgrade o servizi personalizzati; creare pacchetti premium per questi clienti

Obiettivo: Aumentare il valore medio della prenotazione

Pricing Dinamico tramite Probabilità del Modello

Insight: Il modello produce una probabilità di conferma per ogni prenotazione

Azione: Alta probabilità → prezzo leggermente più alto; bassa probabilità → sconto o incentivo

Obiettivo: Massimizzare i ricavi mantenendo un buon tasso di occupazione

Validazione del Modello su Dati Nuovi (2024)

Il modello LightGBM è stato addestrato sui dati storici (2015–2017). In questa fase lo applico ai dati del 2024 per testarne l'efficacia in uno scenario realistico..

Questa sezione simula l'uso operativo, confrontando le previsioni su dati nuovi e sconosciuti con gli esiti reali per misurare la precisione.

Esploreremo l'intera pipeline: dalla preparazione dei dati 2024 alla valutazione finale del modello.

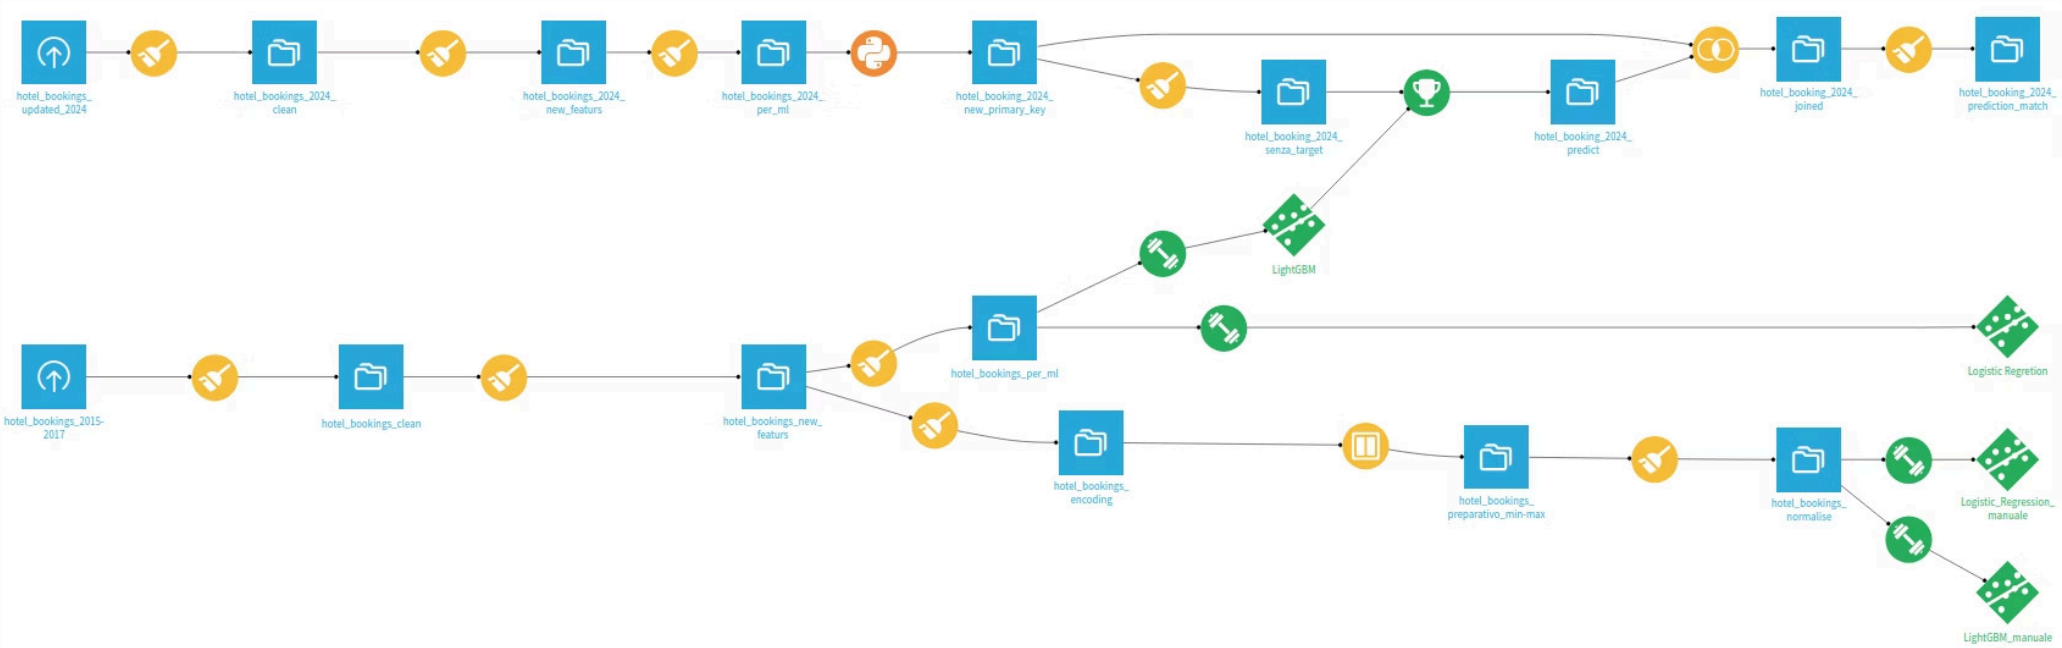

Pipeline 2024: Dalla Preparazione alla Predizione

Questa pipeline illustra il processo end-to-end per applicare il nostro modello LightGBM ai nuovi dati del 2024, trasformando i dati grezzi in previsioni utilizzabili per decisioni strategiche.

Perché rimuovere il target? In uno scenario reale, al momento dello scoring, la variabile `booking_confirmed` (esito futuro) non è ancora nota. Il modello deve prevederla.

A cosa serve `row_id`? Consente di unire in modo sicuro le previsioni del modello con gli esiti reali una volta che diventano disponibili, per una valutazione accurata delle performance.

Output dello Scoring: Probabilità e Predizioni

Cosa Produce il Modello

Il modello LightGBM genera per ogni prenotazione una previsione dettagliata, fondamentale per le decisioni strategiche:

- `proba_0`: Probabilità che la prenotazione sia **cancellata** (Classe 0)
- `proba_1`: Probabilità che la prenotazione sia **confermata** (Classe 1)
- `prediction`: La classe predetta (**0 o 1**), basata sulla soglia definita (**0.375**)

Come Interpretare la Probabilità di Conferma (`proba_1`)

- Se `proba_1` è **vicino a 1** (es. 0.85): Il modello è molto sicuro che la prenotazione sarà **confermata**.
- Se `proba_1` è **vicino a 0.375**: Il modello è incerto; la prenotazione potrebbe andare in entrambi i modi.
- Se `proba_1` è **vicino a 0** (es. 0.15): Il modello è molto sicuro che la prenotazione sarà **cancellata**.

Flessibilità della Soglia:

La soglia standard per la previsione è **0.375** (`prediction` = 1 se `proba_1` > **0.375**). Tuttavia, questa soglia può essere **personalizzata** per allinearsi meglio agli obiettivi di business, ad esempio per ridurre i falsi positivi (cancellazioni previste ma che si confermano) o i falsi negativi (conferme previste ma che si cancellano).

Unione Predizioni e Realtà: Join su row_id

Cosa ho fatto e perché

Dopo aver applicato il modello al dataset 2024, ho ottenuto le predizioni (proba_1, prediction) per ogni prenotazione. Per valutare quanto il modello sia accurato, ho dovuto confrontare queste predizioni con gli esiti reali (booking_confirmed). Il problema è che le predizioni e il target reale si trovano in due dataset separati — quindi ho dovuto unirli.

> Non potevo fare una join su colonne come lead_time o mese di arrivo: valori uguali in righe diverse avrebbero creato duplicati o match sbagliati. Serviva una chiave univoca.

1

Aggiungo row_id

Prima dello scoring, assegno un numero sequenziale (0, 1, 2, ...) a ogni riga del dataset 2024. Ogni prenotazione ha ora un ID unico.

2

Scoring senza target

Rimuovo booking_confirmed e applico il modello. Output: proba_1 e prediction per ogni row_id.

3

Join su row_id

Unisco le predizioni con il target reale usando row_id come chiave. Risultato: un dataset completo con proba_1, prediction e booking_confirmed.

Perché questo approccio è corretto

Questo processo simula esattamente uno scenario reale: il modello predice senza conoscere l'esito, e solo dopo confrontiamo con la realtà per misurare la qualità.

Nessun data leakage

Il target booking_confirmed non è mai visibile al modello durante la predizione — esattamente come accadrebbe in produzione.

Join 1-a-1 garantita

row_id è univoco per costruzione: ogni predizione corrisponde esattamente a una sola riga reale, senza duplicati.

Dataset finale pronto

`hotel_booking_2024_joined` contiene: row_id, proba_1, prediction, booking_confirmed — tutto il necessario per calcolare accuracy, precision, recall e F1.

Risultati della Valutazione: Performance del Modello su Dati 2024

Matrice di Confusione

La matrice di confusione mostra la distribuzione delle previsioni del modello rispetto agli esiti reali sul dataset del 2024.

	Predizione: 0 (Cancellata)	**Predizione: 1 (Confermata)**
Reale: 0 (Cancellata)	34 698 (TN)	9 456 (FP)
Reale: 1 (Confermata)	6 919 (FN)	67 821 (TP)

Totale prenotazioni valutate: 119,383

Metriche di Performance

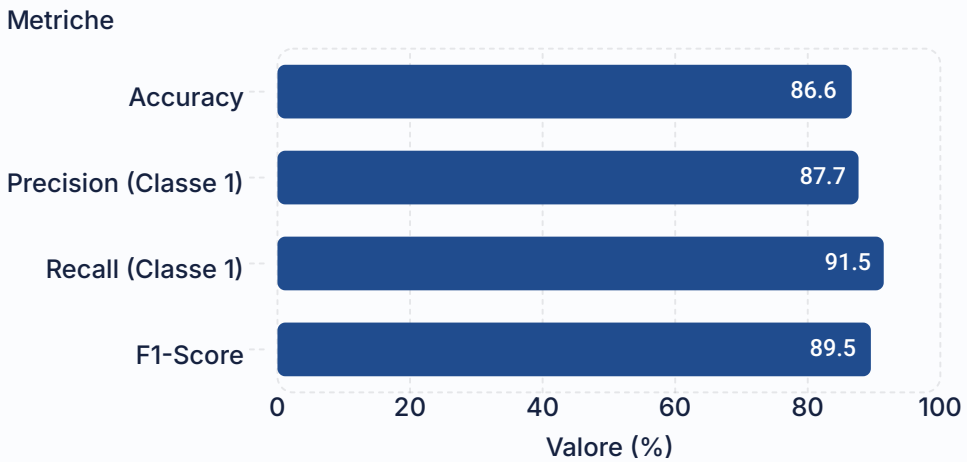

Queste metriche riassumono l'efficacia del modello nel prevedere le cancellazioni e le conferme.

Il grafico a barre mostra il valore percentuale delle metriche di valutazione chiave del modello. Con valori elevati sia per Precision che per Recall (entrambi superiori all'87%), il modello si dimostra ben bilanciato e affidabile sia nell'identificare correttamente le conferme sia nell'evitare falsi positivi.

Interpretazione Pratica

- **Alto Recall (91.46%):** Il modello cattura la grande maggioranza delle prenotazioni che si confermeranno.
- **Alta Precision (87.66%):** Quando il modello predice una conferma, ha ragione l'87.66% delle volte — molto più affidabile della versione precedente.
- **F1-Score elevato (89.52%):** Ottimo bilanciamento tra precision e recall.
- **Accuracy (86.63%):** Il modello classifica correttamente quasi 9 prenotazioni su 10.

In sintesi, il modello è ora più equilibrato e affidabile, con un'alta capacità di identificare le prenotazioni confermate (alto Recall) e una maggiore affidabilità nelle sue previsioni di conferma (alta Precision).

Possibili Miglioramenti e Trade-off

Aumentare la Soglia di `proba_1`:

- Per ridurre i Falsi Positivi (prenotazioni previste come confermate ma che si cancellano), potremmo aumentare la soglia di decisione per `proba_1` (es. da **0.375** a 0.5 o 0.6).
- **Implicazione:** Questo aumenterebbe ulteriormente la Precision (il modello sarebbe ancora più affidabile quando predice una conferma), ma potrebbe ridurre il Recall (potrebbe non catturare tutte le conferme reali, aumentando i Falsi Negativi).

Il trade-off tra Precision e Recall deve essere bilanciato in base agli obiettivi di business specifici. Se l'hotel preferisce non rischiare di overbookare (alta precisione nelle conferme), potrebbe voler aumentare la soglia. Se invece l'obiettivo primario è non perdere nessuna prenotazione confermata (alto recall), la soglia attuale potrebbe essere più adeguata.

Validazione Completata: Modello Pronto per il Deployment

Cosa Abbiamo Imparato

I rigorosi test sul modello predittivo delle cancellazioni hanno fornito risultati chiari e incoraggianti:

Robustezza Verificata

Il modello LightGBM, addestrato su dati 2015-2017, ha mantenuto un'accuratezza dell'86.63% su dati completamente nuovi del 2024. Questo dimostra una forte capacità di generalizzazione e assenza di overfitting.

Coerenza delle Performance

Le performance osservate durante la fase di validazione sono coerenti con quelle registrate durante il training iniziale, confermando l'affidabilità del modello in scenari reali.

Punti di Forza del Modello

Performance Bilanciate ed Elevate

Il modello dimostra un Recall elevato (91.46%), identificando la grande maggioranza delle prenotazioni che si confermeranno, e un'altrettanto forte Precisione (87.66%), garantendo che le sue previsioni di conferma siano altamente affidabili. L'alto F1-Score (89.52%) conferma un ottimo bilanciamento tra queste metriche.

Affidabilità nelle Conferme

La sua elevata capacità di "catturare" le conferme e l'affidabilità nelle previsioni lo rendono uno strumento robusto per identificare le prenotazioni stabili, permettendo decisioni più sicure riguardo all'allocazione delle risorse e minimizzando il rischio di overbooking e perdite di opportunità.

Aree di Ulteriore Ottimizzazione

- **Riduzione dei Falsi Positivi Residui:** Sebbene la Precisione sia ora elevata, c'è sempre spazio per affinare ulteriormente il modello per minimizzare i falsi positivi residui (prenotazioni previste come confermate che si cancellano). Questo può essere raggiunto attraverso un'ulteriore ingegnerizzazione delle feature (feature engineering) o un tuning più fine degli iperparametri, concentrandosi sulle casistiche borderline.
- **Soglia Adattabile:** Esiste la possibilità di aggiustare la soglia di decisione per `proba_1`, personalizzandola in base agli specifici obiettivi di business (es. priorità assoluta alla riduzione dell'overbooking vs. massimizzazione delle occupazioni con un rischio controllato di cancellazioni non previste). Questo consente una flessibilità operativa per l'hotel.

Il Percorso del Progetto — Dal Dato alla Decisione

Definizione del Problema

Classificazione binaria: prevedere se una prenotazione sarà confermata (1) o cancellata (0). Dataset: ~120.000 prenotazioni, 30+ variabili.

Preparazione dei Dati

Pulizia dei dati (null, categorie rare, outlier) e feature engineering: season, lead_time_group, trip_type, country_group, weekend_flag.

Analisi Esplorativa (EDA)

Identificati i fattori chiave: lead_time alto → più cancellazioni; Direct/Corporate → più affidabili; special requests → segnale di conferma.

Modellazione

Testati Logistic Regression (ROC AUC 0.91) e LightGBM (ROC AUC 0.942). LightGBM scelto come modello finale per la sua superiorità.

Validazione su Dati 2024

Modello applicato su dati completamente nuovi (2024): Accuracy 86.63%, Precision 87.66%, Recall 91.46%, F1 89.52%. Nessun overfitting.

Strategie di Business

8 strategie operative derivate dal modello: depositi intelligenti, pricing dinamico, gestione canali, ottimizzazione agenti e altro.

Feature più Importanti del Modello

20%	19%	11%	9%
deposit_type	country_group	market_segment	agent_group

7.8%	7%	6%
special_requests_group	lead_time	customer_type

Il Risultato

Il modello LightGBM, addestrato su dati 2015–2017 e validato su dati 2024, classifica correttamente l'86.63% delle prenotazioni — con un Recall del 91.46% e una Precision dell'87.66%. Un sistema pronto per guidare decisioni operative concrete nel settore alberghiero.

Conclusioni — Risultati Concreti del Progetto

Il Modello Funziona

0.942

ROC AUC — LightGBM

86.63%

Accuracy su dati 2024

91.46%

Recall — conferme catturate

87.66%

Precision — affidabilità previsioni

Cosa ho Scoperto

Il deposito è il segnale più forte

deposit_type è la variabile più importante (20%). Chi paga un deposito non rimborsabile quasi non cancella mai.

Il Portogallo è un'anomalia critica

Il 40.9% delle prenotazioni viene dal Portogallo, ma solo il 43.3% si conferma — il tasso più basso tra tutti i paesi (country_group: 19% di importanza).

Online TA genera il maggior rischio assoluto

Con il 47.4% del volume totale e solo il 63% di conferme, Online TA è la principale fonte di cancellazioni in termini assoluti.

Le richieste speciali sono un segnale quasi infallibile

Da 0 richieste (52% di conferme) a 4+ richieste (90%). Chi personalizza il soggiorno raramente cancella.

Due Dataset, Un Solo Modello Robusto

Il modello è stato addestrato su dati 2015–2017 e validato su dati 2024 completamente nuovi — senza overfitting. Questo dimostra che le relazioni apprese sono reali e generalizzabili, non artefatti del dataset di training.

Dall'Analisi all'Azione

deposit_type Depositi intelligenti per prenotazioni a rischio	**country_group** Politiche differenziate per paese
market_segment Incentivi per Direct/Corporate, restrizioni per OTA	**agent_group** Monitoraggio e selezione degli agenti
special_requests Upgrade e pacchetti premium per clienti coinvolti	**lead_time** Promozioni last-minute, depositi per prenotazioni anticipate

> Il Machine Learning non ha solo previsto le cancellazioni — ha rivelato le leve concrete su cui agire. Ogni strategia di business è direttamente giustificata dai dati.